

# 卡尔曼滤波基本理论

NXP

21 June 2016

## 摘要

本文推导了标准卡尔曼滤波方程。

## 1 简介

本文推导了标准卡尔曼滤波方程。它的目的是作为一个初级读物，应在处理应用说明 AN5023 “传感器融合卡尔曼滤波器”之前阅读，该说明描述了用于NXP 传感器融合库软件中加速计、磁强计和陀螺仪数据融合的更专业的间接互补卡尔曼滤波器。

第2节计算了推导过程中用到的一些数学结论。推导本身在第3节。

### 1.1 术语

符号	定义
$\mathbf{A}_k$	样本 $k$ 时的线性预测或状态矩阵。 $\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{w}_k$ $\hat{\mathbf{x}}_k^- = \mathbf{A}_k \hat{\mathbf{x}}_{k-1}^+$
$\mathbf{C}_k$	样本 $k$ 时 $\mathbf{z}_k$ 到 $\mathbf{x}_k$ 的测量矩阵。 $\mathbf{z}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{v}_k$
$E[\cdot]$	期望运算符
$\mathbf{K}_k$	样本 $k$ 时的卡尔曼滤波增益矩阵。
$\mathbf{P}_k^-$	样本 $k$ 时线性预测 (先验) 误差 $\hat{\mathbf{x}}_{\varepsilon,k}^-$ 的先验协方差矩阵。 $\mathbf{P}_k^- = E [\hat{\mathbf{x}}_{\varepsilon,k}^- \hat{\mathbf{x}}_{\varepsilon,k}^{-T}]$
$\mathbf{P}_k^+$	样本 $k$ 时卡尔曼 (后验) 误差 $\hat{\mathbf{x}}_{\varepsilon,k}^+$ 的后验协方差矩阵。 $\mathbf{P}_k^+ = E [\hat{\mathbf{x}}_{\varepsilon,k}^+ \hat{\mathbf{x}}_{\varepsilon,k}^{+T}]$
$\mathbf{Q}_{w,k}$	过程 $\mathbf{x}_k$ 中加性噪声 $\mathbf{w}_k$ 的协方差矩阵。 $\mathbf{Q}_{w,k} = E [\mathbf{w}_k \mathbf{w}_k^T]$
$\mathbf{Q}_{v,k}$	测量过程 $\mathbf{z}_k$ 中加性噪声 $\mathbf{v}_k$ 的协方差矩阵。 $\mathbf{Q}_{v,k} = E [\mathbf{v}_k \mathbf{v}_k^T]$
$V[\cdot]$	方差运算符
$\mathbf{v}_k$	样本 $k$ 时测量过程 $\mathbf{z}_k$ 中的加性噪声。
$\mathbf{w}_k$	样本 $k$ 时过程中感兴趣的 $\mathbf{x}_k$ 的加性噪声。

符号	定义
$\mathbf{x}_k$	时间样本 $k$ 时的过程 $\mathbf{x}_k$ 的状态向量。 $\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{w}_k$
$\hat{\mathbf{x}}_k^-$	样本 $k$ 时过程 $\mathbf{x}_k$ 的线性预测 (先验) 估计。 $\hat{\mathbf{x}}_k^- = \mathbf{A}_k \hat{\mathbf{x}}_{k-1}^+$
$\hat{\mathbf{x}}_k^+$	样本 $k$ 时过程 $\mathbf{x}_k$ 的卡尔曼滤波 (后验) 估计。 $\hat{\mathbf{x}}_k^+ = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \hat{\mathbf{x}}_k^- + \mathbf{K}_k \mathbf{z}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{A}_k \hat{\mathbf{x}}_{k-1}^+ + \mathbf{K}_k \mathbf{z}_k$
$\hat{\mathbf{x}}_{\varepsilon,k}^-$	过程 $\mathbf{x}_k$ 的线性预测 (先验) 估计中的误差。 $\hat{\mathbf{x}}_{\varepsilon,k}^- = \hat{\mathbf{x}}_k^- - \mathbf{x}_k$
$\hat{\mathbf{x}}_{\varepsilon,k}^+$	过程 $\mathbf{x}_k$ 的后验卡尔曼滤波估计误差。 $\hat{\mathbf{x}}_{\varepsilon,k}^+ = \hat{\mathbf{x}}_k^+ - \mathbf{x}_k$
$\mathbf{z}_k$	样本 $k$ 时的测量过程。 $\mathbf{z}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{v}_k$
$\delta_{kj}$	Kronecker $\delta$ 函数。对于 $k = j$ 则 $\delta_{k,j} = 1$ , 否则为 0。

## 2 数学引理

### 2.1 引理 1

两个方阵  $\mathbf{A}$  和  $\mathbf{B}$  之和的迹等于各个迹的和。证明是简单的。

$$\text{tr}(\mathbf{A} + \mathbf{B}) = \sum_{i=0}^{N-1} A_{ii} + B_{ii} = \sum_{i=0}^{N-1} A_{ii} + \sum_{i=0}^{N-1} B_{ii} = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B}) \quad (1)$$

### 2.2 引理 2

矩阵积  $\mathbf{C} = \mathbf{AB}$  的迹对  $\mathbf{A}$  的导数等于  $\mathbf{B}^T$ 。

$$\frac{\partial \{\text{tr}(\mathbf{C})\}}{\partial \mathbf{A}} = \frac{\partial \{\text{tr}(\mathbf{AB})\}}{\partial \mathbf{A}} = \begin{pmatrix} \left( \frac{\partial \text{tr}(\mathbf{AB})}{\partial A_{0,0}} \right) & \left( \frac{\partial \text{tr}(\mathbf{AB})}{\partial A_{0,1}} \right) & \cdots & \left( \frac{\partial \text{tr}(\mathbf{AB})}{\partial A_{0,N-1}} \right) \\ \left( \frac{\partial \text{tr}(\mathbf{AB})}{\partial A_{1,0}} \right) & \left( \frac{\partial \text{tr}(\mathbf{AB})}{\partial A_{1,1}} \right) & \cdots & \left( \frac{\partial \text{tr}(\mathbf{AB})}{\partial A_{1,N-1}} \right) \\ \cdots & \cdots & \cdots & \cdots \\ \left( \frac{\partial \text{tr}(\mathbf{AB})}{\partial A_{M-1,0}} \right) & \left( \frac{\partial \text{tr}(\mathbf{AB})}{\partial A_{M-1,1}} \right) & \cdots & \left( \frac{\partial \text{tr}(\mathbf{AB})}{\partial A_{M-1,N-1}} \right) \end{pmatrix} \quad (2)$$

证明: 如果矩阵  $\mathbf{A}$  的维数为  $M \times N$ , 矩阵  $\mathbf{B}$  的维数为  $N \times M$ , 则  $\mathbf{C} = \mathbf{AB}$  的维数为  $M \times M$ 。矩阵  $\mathbf{C}$  的元素  $C_{ij}$  的值为:

$$C_{ij} = \sum_{k=0}^{N-1} A_{ik} B_{kj} \Rightarrow \text{tr}(\mathbf{C}) = \text{tr}(\mathbf{AB}) = \sum_{i=0}^{M-1} C_{ii} = \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki} \quad (3)$$

将方程 (3) 代入方程 (2) 得到:

$$\frac{\partial \{\text{tr}(\mathbf{A}\mathbf{B})\}}{\partial \mathbf{A}} = \begin{pmatrix} \left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{0,0}} \right) & \left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{0,1}} \right) & \cdots & \left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{0,N-1}} \right) \\ \left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{1,0}} \right) & \left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{1,1}} \right) & \cdots & \left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{1,N-1}} \right) \\ \cdots & \cdots & \cdots & \cdots \\ \left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{M-1,0}} \right) & \left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{M-1,1}} \right) & \cdots & \left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{M-1,N-1}} \right) \end{pmatrix} \quad (4)$$

通过检查：

$$\left( \frac{\partial \sum_{i=0}^{M-1} \sum_{k=0}^{N-1} A_{ik} B_{ki}}{\partial A_{lm}} \right) = B_{ml} \quad (5)$$

将方程 (5) 代入方程 (4) 完成证明：

$$\frac{\partial \{\text{tr}(\mathbf{A}\mathbf{B})\}}{\partial \mathbf{A}} = \begin{pmatrix} B_{0,0} & B_{1,0} & \cdots & B_{N-1,0} \\ B_{0,1} & B_{1,1} & \cdots & B_{N-1,1} \\ \cdots & \cdots & \cdots & \cdots \\ B_{0,M-1} & B_{1,M-1} & \cdots & B_{N-1,M-1} \end{pmatrix} = \mathbf{B}^T \quad (6)$$

### 2.3 引理 3

矩阵积  $\mathbf{A}\mathbf{B}\mathbf{A}^T$  的迹对  $\mathbf{A}$  的导数等于  $\mathbf{A}(\mathbf{B} + \mathbf{B}^T)$ 。

$$\frac{\partial \{\text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)\}}{\partial \mathbf{A}} = \begin{pmatrix} \left( \frac{\partial \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)}{\partial A_{0,0}} \right) & \left( \frac{\partial \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)}{\partial A_{0,1}} \right) & \cdots & \left( \frac{\partial \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)}{\partial A_{0,N-1}} \right) \\ \left( \frac{\partial \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)}{\partial A_{1,0}} \right) & \left( \frac{\partial \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)}{\partial A_{1,1}} \right) & \cdots & \left( \frac{\partial \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)}{\partial A_{1,N-1}} \right) \\ \cdots & \cdots & \cdots & \cdots \\ \left( \frac{\partial \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)}{\partial A_{M-1,0}} \right) & \left( \frac{\partial \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)}{\partial A_{M-1,1}} \right) & \cdots & \left( \frac{\partial \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)}{\partial A_{M-1,N-1}} \right) \end{pmatrix} \quad (7)$$

证明：如果矩阵  $\mathbf{A}$  的维数为  $M \times N$ ，那么矩阵  $\mathbf{B}$  必须是维数为  $N \times N$  的方阵，矩阵积  $\mathbf{A}\mathbf{B}\mathbf{A}^T$  才能存在。矩阵积  $\mathbf{A}\mathbf{B}\mathbf{A}^T$  总是方阵，维数为  $M \times M$ 。

矩阵  $\mathbf{C} = \mathbf{A}\mathbf{B}$  的元素  $C_{ij}$  的值为：

$$C_{ij} = \sum_{k=0}^{N-1} A_{ik} B_{kj} \quad (8)$$

矩阵  $\mathbf{D} = \mathbf{A}\mathbf{B}\mathbf{A}^T = \mathbf{C}\mathbf{A}^T$  的元素  $D_{il}$  有值：

$$D_{il} = \sum_{j=0}^{N-1} C_{ij} A_{lj} = \sum_{j=0}^{N-1} \sum_{k=0}^{N-1} A_{ik} B_{kj} A_{lj} \quad (9)$$

矩阵  $\mathbf{D}$  的迹等于：

$$\text{tr}(\mathbf{D}) = \sum_{i=0}^{N-1} D_{ii} = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} \sum_{k=0}^{N-1} A_{ik} B_{kj} A_{ij} \quad (10)$$

$\text{tr}(\mathbf{D})$  对  $A_{lm}$  的导数是:

$$\left( \frac{\partial \text{tr}(\mathbf{D})}{\partial A_{lm}} \right) = \left( \frac{\partial \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} \sum_{k=0}^{N-1} A_{ik} B_{kj} A_{ij}}{\partial A_{lm}} \right) = \left( \frac{\partial \sum_{j=0}^{N-1} \sum_{k=0}^{N-1} A_{lk} B_{kj} A_{lj}}{\partial A_{lm}} \right) \quad (11)$$

$$= \sum_{j=0}^{N-1} A_{lj} B_{mj} + \sum_{j=0}^{N-1} A_{lj} B_{jm} = (\mathbf{A}\mathbf{B}^T)_{lm} + (\mathbf{A}\mathbf{B})_{lm} \quad (12)$$

$$\Rightarrow \frac{\partial \{\text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)\}}{\partial \mathbf{A}} = \mathbf{A}(\mathbf{B} + \mathbf{B}^T) \quad (13)$$

如果  $\mathbf{B}$  也是对称的, 则:

$$\frac{\partial \{\text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T)\}}{\partial \mathbf{A}} = 2\mathbf{A}\mathbf{B} \text{ if } \mathbf{B} = \mathbf{B}^T \quad (14)$$

### 3 卡尔曼滤波推导

#### 3.1 过程模型

卡尔曼滤波器用线性和递归模型对感兴趣的  $\mathbf{x}_k$  向量过程进行建模:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{w}_k \quad (15)$$

如果  $\mathbf{x}_k$  有  $N$  个自由度, 则  $\mathbf{A}_k$  是  $N \times N$  的线性预测矩阵 (可能是时变的, 但假定已知),  $\mathbf{w}_k$  是  $N \times 1$  的零均值白噪声向量。

假设过程  $\mathbf{x}_k$  是不可直接测量的, 并且必须从过程  $\mathbf{z}_k$  估计, 过程  $\mathbf{z}_k$  是可以测量的。 $\mathbf{z}_k$  被建模为与  $\mathbf{x}_k$  线性相关, 并有加性零均值白噪声  $\mathbf{v}_k$ 。

$$\mathbf{z}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{v}_k \quad (16)$$

$\mathbf{z}_k$  是  $M \times 1$  向量,  $\mathbf{C}_k$  是  $M \times N$  矩阵 (可能是时变的, 但假定已知),  $\mathbf{v}_k$  是  $M \times 1$  噪声向量。由于噪声向量  $\mathbf{w}_k$  和  $\mathbf{v}_k$  是零均值白噪声过程, 它们的期望向量为零, 并且它们的协方差矩阵在不同时间  $j$  和  $k$  是不相关的。

$$E[\mathbf{w}_k] = \mathbf{0} \quad (17)$$

$$E[\mathbf{v}_k] = \mathbf{0} \quad (18)$$

$$\text{cov}\{\mathbf{w}_k, \mathbf{w}_j\} = E[\mathbf{w}_k \mathbf{w}_j^T] = \mathbf{Q}_{w,k} \delta_{kj} \quad (19)$$

$$\text{cov}\{\mathbf{v}_k, \mathbf{v}_j\} = E[\mathbf{v}_k \mathbf{v}_j^T] = \mathbf{Q}_{v,k} \delta_{kj} \quad (20)$$

根据定义, 协方差矩阵是对称的, 但不一定是对角的:

$$\mathbf{Q}_{w,k}^T = \{E[\mathbf{w}_k \mathbf{w}_k^T]\}^T = E[(\mathbf{w}_k \mathbf{w}_k^T)^T] = E[\mathbf{w}_k \mathbf{w}_k^T] = \mathbf{Q}_{w,k} \quad (21)$$

协方差矩阵  $\mathbf{Q}_{w,k}$  和  $\mathbf{Q}_{v,k}$  不必是固定的, 可以而且通常会随时间而变化。

### 3.2 推导

卡尔曼滤波器的目标是从 i) 上一次迭代的后验估计  $\hat{\mathbf{x}}_{k-1}^+$  的外推和 ii) 当前测量  $\mathbf{z}_k$ ，计算一个无偏的基本过程  $\mathbf{x}_k$  的一个后验估计  $\hat{\mathbf{x}}_k^+$ ：

$$\hat{\mathbf{x}}_k^+ = \mathbf{K}_k' \hat{\mathbf{x}}_{k-1}^+ + \mathbf{K}_k \mathbf{z}_k \quad (22)$$

时变卡尔曼增益矩阵  $\mathbf{K}_k'$  和  $\mathbf{K}_k$  定义了前一次迭代卡尔曼滤波估计  $\mathbf{K}_k$  和当前测量  $\mathbf{z}_k$  的相对权重。如果测量  $\mathbf{z}_k$  具有更低噪声，则与外推分量  $\mathbf{K}_k' \hat{\mathbf{x}}_{k-1}^+$  相比，测量项  $\mathbf{K}_k \mathbf{z}_k$  具有更高的权重，反之亦然。因此，卡尔曼滤波器是一种时变的递归滤波器。

#### 3.2.1 无偏估计约束 (确定 $\mathbf{K}_k'$ )

对于  $\hat{\mathbf{x}}_k^+$  是  $\mathbf{x}_k$  的无偏估计，后验卡尔曼滤波误差  $\hat{\mathbf{x}}_{\varepsilon,k}^+$  的期望值必须为零：

$$E[\hat{\mathbf{x}}_{\varepsilon,k}^+] = E[\hat{\mathbf{x}}_k^+ - \mathbf{x}_k] = \mathbf{0} \quad (23)$$

从方程 (22) 中代入  $\mathbf{x}_k$  得出：

$$\hat{\mathbf{x}}_{\varepsilon,k}^+ = \hat{\mathbf{x}}_k^+ - \mathbf{x}_k = \mathbf{K}_k' \hat{\mathbf{x}}_{k-1}^+ + \mathbf{K}_k \mathbf{z}_k - \mathbf{x}_k \quad (24)$$

从方程 (16) 代入测量  $\mathbf{z}_k$  得出：

$$\hat{\mathbf{x}}_{\varepsilon,k}^+ = \mathbf{K}_k' \hat{\mathbf{x}}_{k-1}^+ + \mathbf{K}_k (\mathbf{C}_k \mathbf{x}_k + \mathbf{v}_k) - \mathbf{x}_k \quad (25)$$

从方程 (15) 中代入  $\mathbf{x}_k$  并重新排列得到：

$$\hat{\mathbf{x}}_{\varepsilon,k}^+ = \mathbf{K}_k' (\hat{\mathbf{x}}_{\varepsilon,k-1}^+ + \mathbf{x}_{k-1}) + \mathbf{K}_k \{ \mathbf{C}_k (\mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{w}_k) + \mathbf{v}_k \} - (\mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{w}_k) \quad (26)$$

$$= \mathbf{K}_k' \hat{\mathbf{x}}_{\varepsilon,k-1}^+ + (\mathbf{K}_k \mathbf{C}_k \mathbf{A}_k - \mathbf{A}_k + \mathbf{K}_k') \mathbf{x}_{k-1} + (\mathbf{K}_k \mathbf{C}_k - \mathbf{I}) \mathbf{w}_k + \mathbf{K}_k \mathbf{v}_k \quad (27)$$

取方程 (27) 的期望值并应用无偏估计约束得出：

$$E[\hat{\mathbf{x}}_{\varepsilon,k}^+] = E[\mathbf{K}_k' \hat{\mathbf{x}}_{\varepsilon,k-1}^+] + E[(\mathbf{K}_k \mathbf{C}_k \mathbf{A}_k - \mathbf{A}_k + \mathbf{K}_k') \mathbf{x}_{k-1}] + E[(\mathbf{K}_k \mathbf{C}_k - \mathbf{I}) \mathbf{w}_k] + E[\mathbf{K}_k \mathbf{v}_k] = \mathbf{0} \quad (28)$$

由于噪声矢量  $\mathbf{w}_k$  和  $\mathbf{v}_k$  是零均值，并且与同时迭代的卡尔曼矩阵不相关，因此如下所示：

$$E[(\mathbf{K}_k \mathbf{C}_k - \mathbf{I}) \mathbf{w}_k] = E[\mathbf{K}_k \mathbf{v}_k] = \mathbf{0} \quad (29)$$

另外假设过程  $\mathbf{x}_{k-1}$  独立于迭代  $k$  时缓慢变化的矩阵  $\mathbf{A}_k$ 、 $\mathbf{C}_k$ 、 $\mathbf{K}_k$  和  $\mathbf{K}_k'$ ：

$$E[(\mathbf{K}_k \mathbf{C}_k \mathbf{A}_k - \mathbf{A}_k + \mathbf{K}_k') \mathbf{x}_{k-1}] = (\mathbf{K}_k \mathbf{C}_k \mathbf{A}_k - \mathbf{A}_k + \mathbf{K}_k') E[\mathbf{x}_{k-1}] = \mathbf{0} \quad (30)$$

因为  $\mathbf{x}_k$  通常不是一个零均值过程：

$$\mathbf{K}_k \mathbf{C}_k \mathbf{A}_k - \mathbf{A}_k + \mathbf{K}_k' = \mathbf{0} \Rightarrow \mathbf{K}_k' = \mathbf{A}_k - \mathbf{K}_k \mathbf{C}_k \mathbf{A}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{A}_k \quad (31)$$

代入方程 (22) 中的  $\mathbf{K}'_k$ , 得到:

$$\hat{\mathbf{x}}_k^+ = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{A}_k \hat{\mathbf{x}}_{k-1}^+ + \mathbf{K}_k \mathbf{z}_k \quad (32)$$

### 3.2.2 先验估计

先验卡尔曼滤波估计  $\hat{\mathbf{x}}_k^-$  是将线性预测矩阵  $\mathbf{A}_k$  应用于上一次迭代的后验估计  $\hat{\mathbf{x}}_{k-1}^+$  的结果:

$$\hat{\mathbf{x}}_k^- = \mathbf{A}_k \hat{\mathbf{x}}_{k-1}^+ \quad \text{Kalman equation (A)} \quad (33)$$

### 3.2.3 后验估计的定义

将方程 (33) 中的先验估计  $\hat{\mathbf{x}}_k^-$  代入方程 (32), 得出:

$$\hat{\mathbf{x}}_k^+ = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \hat{\mathbf{x}}_k^- + \mathbf{K}_k \mathbf{z}_k \quad \text{Kalman equation (D)} \quad (34)$$

等效形式为:

$$\hat{\mathbf{x}}_k^+ = \hat{\mathbf{x}}_k^- + \mathbf{K}_k (\mathbf{z}_k - \mathbf{C}_k \hat{\mathbf{x}}_k^-) \quad (35)$$

从方程 (16) 中, 项  $\mathbf{C}_k \hat{\mathbf{x}}_k^-$  可解释为测量  $\mathbf{z}_k$  的先验估计值  $\hat{\mathbf{z}}_k^-$ , 给出方程 (34) 的另一形式:

$$\hat{\mathbf{x}}_k^+ = \hat{\mathbf{x}}_k^- + \mathbf{K}_k (\mathbf{z}_k - \hat{\mathbf{z}}_k^-) \quad (36)$$

### 3.2.4 $\mathbf{P}_k^-$ 做为 $\mathbf{P}_{k-1}^+$ 的函数

先验和后验误差协方差矩阵  $\mathbf{P}_k^-$  和  $\mathbf{P}_k^+$  定义为:

$$\mathbf{P}_k^- = \text{cov} \{ \hat{\mathbf{x}}_{\varepsilon,k}^-, \hat{\mathbf{x}}_{\varepsilon,k}^- \} = E [\hat{\mathbf{x}}_{\varepsilon,k}^- \hat{\mathbf{x}}_{\varepsilon,k}^{-\text{T}}] = E [(\hat{\mathbf{x}}_k^- - \mathbf{x}_k) (\hat{\mathbf{x}}_k^- - \mathbf{x}_k)^{\text{T}}] \quad (37)$$

$$\mathbf{P}_k^+ = \text{cov} \{ \hat{\mathbf{x}}_{\varepsilon,k}^+, \hat{\mathbf{x}}_{\varepsilon,k}^+ \} = E [\hat{\mathbf{x}}_{\varepsilon,k}^+ \hat{\mathbf{x}}_{\varepsilon,k}^{+\text{T}}] = E [(\hat{\mathbf{x}}_k^+ - \mathbf{x}_k) (\hat{\mathbf{x}}_k^+ - \mathbf{x}_k)^{\text{T}}] \quad (38)$$

将  $\hat{\mathbf{x}}_k^-$  的定义方程 (33) 和  $\mathbf{x}_k$  的定义方程 (15) 代入方程 (37) 中给出了将当前先验误差协方差  $\mathbf{P}_k^-$  与上一次迭代的后验误差协方差估计  $\mathbf{P}_{k-1}^+$  相关的表达式:

$$\mathbf{P}_k^- = E [(\mathbf{A}_k \hat{\mathbf{x}}_{k-1}^+ - \mathbf{A}_k \mathbf{x}_{k-1} - \mathbf{w}_k) (\mathbf{A}_k \hat{\mathbf{x}}_{k-1}^+ - \mathbf{A}_k \mathbf{x}_{k-1} - \mathbf{w}_k)^{\text{T}}] \quad (39)$$

$$= E [\{ \mathbf{A}_k (\hat{\mathbf{x}}_{k-1}^+ - \mathbf{x}_{k-1}) - \mathbf{w}_k \} \{ \mathbf{A}_k (\hat{\mathbf{x}}_{k-1}^+ - \mathbf{x}_{k-1}) - \mathbf{w}_k \}^{\text{T}}] \quad (40)$$

$$= \mathbf{A}_k E [(\hat{\mathbf{x}}_{k-1}^+ - \mathbf{x}_{k-1}) (\hat{\mathbf{x}}_{k-1}^+ - \mathbf{x}_{k-1})^{\text{T}}] \mathbf{A}_k^{\text{T}} + \mathbf{Q}_{w,k} \quad (41)$$

$$\Rightarrow \mathbf{P}_k^- = \mathbf{A}_k \mathbf{P}_{k-1}^+ \mathbf{A}_k^{\text{T}} + \mathbf{Q}_{w,k} \quad \text{Kalman equation (B1)} \quad (42)$$

### 3.2.5 最小误差协方差约束 (确定 $K_k$ )

卡尔曼增益矩阵  $K_k$  通过后验误差协方差矩阵  $P_k^+$  的迹最小化后验误差  $\hat{x}_{\varepsilon,k}^+$  方差:

$$E [\hat{x}_{\varepsilon,k}^{+\text{T}} \hat{x}_{\varepsilon,k}^+] = \text{tr} (P_k^+) \quad (43)$$

为  $z_k$  将方程 (16) 代入方程 (32), 得到了后验误差和先验误差之间的关系:

$$\hat{x}_k^+ = \hat{x}_{\varepsilon,k}^+ + x_k = (I - K_k C_k) (\hat{x}_{\varepsilon,k}^- + x_k) + K_k (C_k x_k + v_k) \quad (44)$$

$$\Rightarrow \hat{x}_{\varepsilon,k}^+ + x_k = (I - K_k C_k) \hat{x}_{\varepsilon,k}^- + x_k - K_k C_k x_k + K_k (C_k x_k + v_k) \quad (45)$$

$$\Rightarrow \hat{x}_{\varepsilon,k}^+ = (I - K_k C_k) \hat{x}_{\varepsilon,k}^- + K_k v_k \quad (46)$$

将该结果代入方程 (38) 中的后验协方差矩阵  $P_k^+$  的定义中, 得到:

$$P_k^+ = E \left[ \{ (I - K_k C_k) \hat{x}_{\varepsilon,k}^- + K_k v_k \} \{ (I - K_k C_k) \hat{x}_{\varepsilon,k}^- + K_k v_k \}^{\text{T}} \right] \quad (47)$$

$$= (I - K_k C_k) E [\hat{x}_{\varepsilon,k}^- \hat{x}_{\varepsilon,k}^{-\text{T}}] (I - K_k C_k)^{\text{T}} + K_k E [v_k v_k^{\text{T}}] K_k^{\text{T}} \quad (48)$$

$$= (I - K_k C_k) P_k^- (I - K_k C_k)^{\text{T}} + K_k Q_{v,k} K_k^{\text{T}} \quad (49)$$

$$= P_k^- - P_k^- C_k^{\text{T}} K_k^{\text{T}} - K_k C_k P_k^- + K_k C_k P_k^- C_k^{\text{T}} K_k^{\text{T}} + K_k Q_{v,k} K_k^{\text{T}} \quad (50)$$

卡尔曼滤波增益  $K_k$  是使后验误差协方差矩阵  $P_k^+$  的迹最小化, 如方程 (43) 所示:

$$\frac{\partial}{\partial K_k} \text{tr} (P_k^+) = \frac{\partial}{\partial K_k} \{ \text{tr} (P_k^-) - \text{tr} (P_k^- C_k^{\text{T}} K_k^{\text{T}}) - \text{tr} (K_k C_k P_k^-) + \text{tr} (K_k C_k P_k^- C_k^{\text{T}} K_k^{\text{T}}) + \text{tr} (K_k Q_{v,k} K_k^{\text{T}}) \} = 0 \quad (51)$$

第一项  $\text{tr} (P_k^-)$  不依赖于  $K_k$ , 得到:

$$\frac{\partial \{ \text{tr} (P_k^-) \}}{\partial K_k} = \frac{\partial \{ \text{tr} (A_k P_{k-1}^+ A_k^{\text{T}} + Q_{w,k}) \}}{\partial K_k} = 0 \quad (52)$$

因为矩阵的迹显然不受转置的影响, 所以可以使用方程 (6) 对方程 (51) 的第二项进行转置和简化, 从而得到:

$$\frac{\partial \{ \text{tr} (P_k^- C_k^{\text{T}} K_k^{\text{T}}) \}}{\partial K_k} = \frac{\partial \{ \text{tr} (K_k C_k P_k^-) \}}{\partial K_k} = (C_k P_k^-)^{\text{T}} = P_k^- C_k^{\text{T}} \quad (53)$$

利用协方差矩阵  $P_k^-$  是对称的这一事实, 可以使用方程 (13) 和 (14) 简化第四项:

$$\frac{\partial \{ \text{tr} (K_k C_k P_k^- C_k^{\text{T}} K_k^{\text{T}}) \}}{\partial K_k} = K_k \left\{ C_k P_k^- C_k^{\text{T}} + (C_k P_k^- C_k^{\text{T}})^{\text{T}} \right\} = 2 K_k C_k P_k^- C_k^{\text{T}} \quad (54)$$

最后一项也可以使用方程 (13) 和 (14) 以及  $Q_{v,k}$  的对称性来简化:

$$\frac{\partial \{ \text{tr} (K_k Q_{v,k} K_k^{\text{T}}) \}}{\partial K_k} = 2 K_k Q_{v,k} \quad (55)$$

将方程 (52) 至 (55) 代入方程 (51)，得到最优卡尔曼滤波器增益矩阵  $\mathbf{K}_k$  的表达式：

$$-2\mathbf{P}_k^- \mathbf{C}_k^T + 2\mathbf{K}_k \mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T + 2\mathbf{K}_k \mathbf{Q}_{v,k} = \mathbf{0} \quad (56)$$

$$\Rightarrow \mathbf{K}_k (\mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T + \mathbf{Q}_{v,k}) = \mathbf{P}_k^- \mathbf{C}_k^T \quad (57)$$

$$\Rightarrow \mathbf{K}_k = \mathbf{P}_k^- \mathbf{C}_k^T (\mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T + \mathbf{Q}_{v,k})^{-1} \quad \text{Kalman equation (C)} \quad (58)$$

### 3.2.6 $\mathbf{P}_k^+$ 做为 $\mathbf{P}_k^-$ 的函数

重新排列方程 (57) 给出：

$$\mathbf{K}_k \mathbf{Q}_{v,k} = \mathbf{P}_k^- \mathbf{C}_k^T - \mathbf{K}_k \mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T \quad (59)$$

将方程 (59) 中的  $\mathbf{K}_k \mathbf{Q}_{v,k}$  代入方程 (49)，得到：

$$\mathbf{P}_k^+ = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{P}_k^- (\mathbf{I} - \mathbf{C}_k^T \mathbf{K}_k^T) + (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{P}_k^- \mathbf{C}_k^T \mathbf{K}_k^T \quad (60)$$

$$= \mathbf{P}_k^- - \mathbf{K}_k \mathbf{C}_k \mathbf{P}_k^- - \mathbf{P}_k^- \mathbf{C}_k^T \mathbf{K}_k^T + \mathbf{K}_k \mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T \mathbf{K}_k^T + \mathbf{P}_k^- \mathbf{C}_k^T \mathbf{K}_k^T - \mathbf{K}_k \mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T \mathbf{K}_k^T \quad (61)$$

$$\Rightarrow \mathbf{P}_k^+ = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{P}_k^- \quad \text{Kalman equation (E)} \quad (62)$$

这就完成了标准卡尔曼滤波方程的推导。

## 3.3 标准卡尔曼方程

本节简单地重新列出了上一节中导出的关键卡尔曼滤波方程。

### 3.3.1 卡尔曼方程 (A)

线性预测 (先验) 估计  $\hat{\mathbf{x}}_k^-$  是通过将线性预测矩阵  $\mathbf{A}_k$  应用于前一样本的卡尔曼 (后验) 滤波器估计  $\hat{\mathbf{x}}_{k-1}^+$  来实现的。

$$\hat{\mathbf{x}}_k^- = \mathbf{A}_k \hat{\mathbf{x}}_{k-1}^+ \quad (\text{A})$$

### 3.3.2 卡尔曼方程 (B)

然后使用模型矩阵  $\mathbf{A}_k$  和噪声矩阵  $\mathbf{Q}_{w,k}$  更新先验 (线性外推) 误差协方差矩阵  $\mathbf{P}_k^-$ 。

$$\mathbf{P}_k^- = \mathbf{A}_k \mathbf{P}_{k-1}^+ \mathbf{A}_k^T + \mathbf{Q}_{w,k} \quad (\text{B1})$$

可以将卡尔曼方程 (B1) 和 (E) 组合以给出  $\mathbf{P}_k^-$  的递归更新，而无需显式计算卡尔曼方程 (E) 中的后验误差协方差矩阵  $\mathbf{P}_k^+$ ：

$$\mathbf{P}_k^- = \mathbf{A}_k (\mathbf{I} - \mathbf{K}_{k-1} \mathbf{C}_{k-1}) \mathbf{P}_{k-1}^- \mathbf{A}_k^T + \mathbf{Q}_{w,k} \quad (\text{B2})$$

$\mathbf{P}_k^-$  的唯一目的是允许计算卡尔曼增益矩阵  $\mathbf{K}_k$ ，以确定后验估计  $\hat{\mathbf{x}}_k^+$ 。



### 3.3.3 卡尔曼方程 (C)

卡尔曼滤波增益矩阵  $K_k$  更新为：

$$K_k = P_k^- C_k^T (C_k P_k^- C_k^T + Q_{v,k})^{-1} \quad (C)$$

### 3.3.4 卡尔曼方程 (D)

卡尔曼滤波 (后验) 估计  $\hat{x}_k^+$  是根据当前先验估计  $\hat{x}_k^-$  和当前测量  $z_k$  计算得到。

$$\hat{x}_k^+ = \hat{x}_k^- + K_k (z_k - C_k \hat{x}_k^-) = (I - K_k C_k) \hat{x}_k^- + K_k z_k \quad (D)$$

### 3.3.5 卡尔曼方程 (E)

更新后验卡尔曼误差协方差矩阵  $P_k^+$ ，并为下一次迭代做好准备。如果以递归方式更新  $P_k^-$ ，则可以跳过此方程。

$$P_k^+ = (I - K_k C_k) P_k^- \quad (E)$$

## 3.4 极限情况

根据方程 (C)，当测量噪声协方差  $Q_{v,k}$  相对于过程噪声协方差  $Q_{w,k}$  减小时，卡尔曼增益矩阵  $K_k$  满足：

$$K_k C_k P_k^- C_k^T = P_k^- C_k^T \Rightarrow K_k C_k = I \quad (63)$$

利用方程 (D)，后验估计  $\hat{x}_k^+$  仅依赖于测量  $z_k$ ：

$$\hat{x}_k^+ = (I - K_k C_k) \hat{x}_k^- + K_k z_k = K_k z_k \quad (64)$$

当测量噪声协方差  $Q_{v,k}$  相对于过程噪声协方差  $Q_{w,k}$  增加时，卡尔曼增益矩阵  $K_k$  接近零：

$$K_k = P_k^- C_k^T (Q_{v,k})^{-1} = 0 \quad (65)$$

后验过程估计  $\hat{x}_k^+$  然后近似于先验估计  $\hat{x}_k^-$ ：

$$\hat{x}_k^+ = \hat{x}_k^- + K_k (z_k - C_k \hat{x}_k^-) = \hat{x}_k^- \quad (66)$$