

# 协方差矩阵特性

rinterested

2020/12

## 1 Gramian 矩阵

矩阵  $A^T A$  (Gramian 矩阵) 具有以下性质:

- $A^T A$  是一个关键的矩阵结构, 因为它在正交投影中起着重要的作用。协方差矩阵只是特例。
- $A^T A$  是协方差矩阵—你可以定义多元正态分布, 其中  $A^T A$  是协方差矩阵, 参见[这里](#)。
- 这相当于讨论对称半正定矩阵 (symmetric positive semidefinite matrices, s.p.s.d.)—对于某些矩阵  $A$ , 每个对称半正定矩阵都可以写成  $A^T A$ 。

**特性列表:**

1. 对称性
2. 半正定性 (可为零)
3. 实特征值和正特征值
4. 矩阵迹 (trace) 为正 (矩阵迹为特征值之和)
5. 行列式是正的 (行列式是特征值的乘积)
6. 对角线条目都是正数
7. 正交特征向量
8. 可对角化为  $Q\Lambda Q^T$
9. 可以得到 Cholesky 分解。
10.  $A^T A$  的秩与  $A$  的秩相同。
11.  $\ker(A^T A) = \ker(A)$

## 2 协方差矩阵

如果列向量的条目：

$$X = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix}$$

是具有有限方差的随机变量，则协方差矩阵  $\Sigma$  是其  $(i, j)$  项为协方差的矩阵

$$\Sigma_{ij} = \text{cov}(X_i, X_j) = E[(X_i - \mu_i)(X_j - \mu_j)] = E[X_i, X_j] - E[X]E[Y]$$

其中  $\mu_i = E(X_i)$  是向量  $X$  中第  $i$  项的期望值。换句话说，

$$\Sigma = \begin{bmatrix} E[(X_1 - \mu_1)(X_1 - \mu_1)] & E[(X_1 - \mu_1)(X_2 - \mu_2)] & \cdots & E[(X_1 - \mu_1)(X_n - \mu_n)] \\ E[(X_2 - \mu_2)(X_1 - \mu_1)] & E[(X_2 - \mu_2)(X_2 - \mu_2)] & \cdots & E[(X_2 - \mu_2)(X_n - \mu_n)] \\ \vdots & \vdots & \ddots & \vdots \\ E[(X_n - \mu_n)(X_1 - \mu_1)] & E[(X_n - \mu_n)(X_2 - \mu_2)] & \cdots & E[(X_n - \mu_n)(X_n - \mu_n)] \end{bmatrix}$$

对于具有均值向量  $\mu$  的随机向量  $\mathbf{X} \in \mathbb{R}^n$ ，更简洁的定义是  $\mathbb{E}((\mathbf{X} - \mu)(\mathbf{X} - \mu)^T)$ 。

这与维基百科的另一个定义是一致的：

$$\Sigma = E[(X - E[X])(X - E[X])^T]$$

从这篇文章和另一篇文章可知：当数据居中（零均值）时，协方差矩阵为  $\frac{1}{n-1} \mathbf{X}^T \mathbf{X}$ 。

因为协方差矩阵是对称的，所以矩阵是可对角化的，并且特征向量可以归一化，使得它们是正交的：

$$\mathbf{X}\mathbf{X}^T = \mathbf{W}\mathbf{D}\mathbf{W}^T$$

另一方面，对数据矩阵  $\mathbf{X}$  应用 SVD 如下：

$$\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$

同时尝试从这个分解构造协方差矩阵得到

$$\mathbf{X}\mathbf{X}^T = (\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T)(\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T)^T$$

$$\mathbf{X}\mathbf{X}^T = (\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T)(\mathbf{V}\mathbf{\Sigma}\mathbf{U}^T)$$

并且因为  $\mathbf{V}$  是一个正交矩阵 ( $\mathbf{V}^T \mathbf{V} = \mathbf{I}$ )，

$$\mathbf{X}\mathbf{X}^T = \mathbf{U}\mathbf{\Sigma}^2\mathbf{U}^T$$

并且相关对应很容易看出 ( $\mathbf{X}\mathbf{X}^T$  的特征值的平方根是  $\mathbf{X}$  的奇异值，等等)。

### 3 几何解释

正如单变量方差是平均值的平均平方距离一样， $\text{trace}(\hat{\Sigma})$  是到质心的平均平方距离：以  $\bar{\mathbf{X}}$  为中心变量的矩阵， $\hat{\Sigma} = \frac{1}{n} \dot{\mathbf{X}}' \dot{\mathbf{X}}$ ，其中  $\dot{\mathbf{X}}' \dot{\mathbf{X}}$  是  $\dot{\mathbf{X}}$  列的点积矩阵。其对角线元素为  $\dot{\mathbf{X}}'_i \dot{\mathbf{X}}_i = (\mathbf{X}_i - \bar{\mathbf{X}})'(\mathbf{X}_i - \bar{\mathbf{X}})$ ，即变量  $i$  与其平均值的平方距离。因此， $\text{trace}(\hat{\Sigma})$  是单变量方差的自然推广。

第二个推广是  $\det(\hat{\Sigma})$ ：这是描述分布的椭球体体积的度量。更准确地说， $|\det(\hat{\Sigma})|$  是应用线性变换  $\hat{\Sigma}$  后单位立方体体积变化的因子，(见此解释)。以下是行列式为 0.75 的矩阵  $\begin{pmatrix} 1 & -.5 \\ .5 & .5 \end{pmatrix}$  的图示 (左：变换前，右：变换后)：

