

# 什么是特征向量和特征值?

Vincent Spruyt

2014/03

## 摘要

本文以直观的方式解释了什么是特征向量和特征值。此外，我们以一个简单的  $2 \times 2$  矩阵为例，手动进行特征分解。

## 目录

1 序言	1
2 计算特征值	3
3 计算第一特征向量	3
4 计算第二特征向量	4
5 结论	5

## 1 序言

特征向量和特征值在计算机视觉和机器学习中有着广泛的应用。众所周知的例子是用于降维的主成分分析 (Principal Component Analysis, PCA) 或用于人脸识别的特征脸 (EigenFaces)。特征向量和特征值的一个有趣的用法也在我关于误差椭圆 (error ellipses) 的文章中说明。此外，特征分解形成协方差矩阵的几何解释的基础，在最近的一篇文章中讨论。在本文中，我将温和地介绍这个数学概念，并将展示如何手动获得二维方阵的特征分解。

特征向量是当对其应用线性变换时其方向保持不变的向量。考虑下面的图像，其中显示了三个向量。绿色正方形仅用于说明应用于这三个向量中的每个向量的线性变换。




图 1: 当对特征向量应用线性变换 (例如缩放) 时, 特征向量 (红色) 不会改变方向。其他向量 (黄色) 则会。

这种情况下的变换是一个简单的缩放, 在水平方向上因子 2, 在垂直方向上因子 0.5, 这样变换矩阵  $A$  被定义为:

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix}.$$

然后通过将此变换应用为  $\vec{v}' = A\vec{v}$ , 对向量  $\vec{v} = (x, y)$  进行缩放。上图显示一些向量的方向 (以红色显示) 不受此线性变换的影响。这些向量被称为变换的特征向量, 并且唯一地定义了方阵  $A$ 。这种唯一的、确定的关系正是这些向量被称为“特征向量”的原因 (特征 (eigen) 在德语中的意思是“特定 (specific)”)。

一般来说, 矩阵  $A$  的特征向量  $\vec{v}$  是下列向量:

$$A\vec{v} = \lambda\vec{v} \quad (1)$$

其中  $\lambda$  是称为“特征值 (eigenvalue)”的标量值。这意味着向量  $\vec{v}$  上的线性变换完全由  $\lambda$  定义。

我们可以将方程 (1) 改写如下:

$$A\vec{v} - \lambda\vec{v} = 0 \Rightarrow \vec{v}(A - \lambda I) = 0, \quad (2)$$

其中  $I$  是与  $A$  相同维度的单位矩阵。

但是, 假设  $\vec{v}$  不是空向量, 只有当  $(A - \lambda I)$  不可逆时, 才能定义方程 (2)。如果一个方阵是不可逆的, 那就意味着它的行列式 (determinant) 必须等于零。因此, 要找到  $A$  的特征向量, 我们只需求解以下方程:

$$\det(A - \lambda I) = 0. \quad (3)$$

在下面的章节中，我们将通过求解方程 (3) 来确定矩阵  $A$  的特征向量和特征值。在本例中，矩阵  $A$  的定义如下：

$$A = \begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix}. \quad (4)$$

## 2 计算特征值

为了确定本例的特征值，我们用方程 (4) 代替方程 (3) 中的  $A$ ，得到：

$$\det \begin{pmatrix} 2 - \lambda & 3 \\ 2 & 1 - \lambda \end{pmatrix} = 0. \quad (5)$$

计算行列式得出：

$$(2 - \lambda)(1 - \lambda) - 6 = 0 \Rightarrow 2 - 2\lambda - \lambda - \lambda^2 - 6 = 0 \Rightarrow \lambda^2 - 3\lambda - 4 = 0. \quad (6)$$

为了在  $\lambda$  中求解这个二次方程，我们找到了判别式：

$$D = b^2 - 4ac = (-3)^2 - 4 * 1 * (-4) = 9 + 16 = 25.$$

由于判别式是严格正的，这意味着  $\lambda$  存在两个不同的值：

$$\begin{aligned} \lambda_1 &= \frac{-b - \sqrt{D}}{2a} = \frac{3 - 5}{2} = -1, \\ \lambda_2 &= \frac{-b + \sqrt{D}}{2a} = \frac{3 + 5}{2} = 4. \end{aligned} \quad (7)$$

现在我们已经确定了两个特征值  $\lambda_1$  和  $\lambda_2$ 。请注意，大小为  $N \times N$  的方阵总是正好有  $N$  个特征值，每个特征值都有相应的特征向量。特征值指定特征向量的大小。

## 3 计算第一特征向量

我们现在可以通过将方程 (7) 中的特征值插入最初定义问题的方程 (1) 来确定特征向量。然后通过求解这个方程组找到特征向量。

我们首先对特征值  $\lambda_1$  进行此操作，以便找到相应的第一特征向量：

$$\begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} x_{11} \\ x_{12} \end{bmatrix} = -1 \begin{bmatrix} x_{11} \\ x_{12} \end{bmatrix}.$$

因为这只是方程组的矩阵表示法，我们可以用它的等价形式来写：

$$\begin{cases} 2x_{11} + 3x_{12} = -x_{11} \\ 2x_{11} + x_{12} = -x_{12} \end{cases} \quad (8)$$

并且作为  $x_{12}$  的函数求解第一个方程, 得到:

$$x_{11} = -x_{12}. \quad (9)$$

由于特征向量只是表示一个方向 (对应的特征值表示幅度), 所以特征向量的所有标量倍数都是与该特征向量平行的向量, 因此是等价的 (如果我们将向量归一化, 它们都是相等的)。因此, 不必进一步求解上述方程组, 我们可以自由地为  $x_{11}$  或  $x_{12}$  选择一个实值, 并使用方程 (9) 确定另一个实值。

对于这个例子, 我们任意选择  $x_{12} = 1$ , 这样  $x_{11} = -1$ 。因此, 对应于特征值  $\lambda_1$  的特征向量为

$$\vec{v}_1 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}. \quad (10)$$

## 4 计算第二特征向量

第二特征向量的计算类似于第一特征向量所需的计算; 我们现在将特征值  $\lambda_2 = 4$  代入方程 (1), 得到:

$$\begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} x_{21} \\ x_{22} \end{bmatrix} = 4 * \begin{bmatrix} x_{21} \\ x_{22} \end{bmatrix}. \quad (11)$$

写为方程组, 相当于:

$$\begin{cases} 2x_{21} + 3x_{22} = 4x_{21} \\ 2x_{21} + x_{22} = 4x_{22} \end{cases} \quad (12)$$

将第一个方程作为  $x_{21}$  的函数求解, 结果如下:

$$x_{22} = \frac{3}{2}x_{21} \quad (13)$$

然后我们任意选择  $x_{21} = 2$ , 并找到  $x_{22} = 3$ 。因此, 对应于特征值  $\lambda_2 = 4$  的特征向量为

$$\vec{v}_2 = \begin{bmatrix} 3 \\ 2 \end{bmatrix}. \quad (14)$$

## 5 结论

本文综述了特征向量和特征值的理论概念。这些概念在计算机视觉和机器学习中有着重要的应用，如 PCA 降维，特征人脸识别等。

If you're new to this blog, don't forget to subscribe, or follow me on twitter!